CHƯƠNG 1

Giới thiệu đề tài và cơ sở lý thuyết

1.1 Giới thiệu đề tài và lý do lựa chọn

Dữ liệu về lỗi bề mặt thép thường chứa nhiều đặc trưng mô tả một bản ghi, chẳng hạn tọa độ, diện tích, độ sáng, dòng thép và độ dày. Các đặc trưng này tạo điều kiện so sánh những nhóm lỗi từ nhiều góc nhìn. Tuy nhiên, khi chỉ quan sát bảng dữ liệu, người đọc khó nhận ra nhóm nào xuất hiện nhiều, các nhóm khác nhau ở đặc điểm nào và những giá trị nào cần được xem xét kỹ hơn. Vì vậy, cần một quy trình kết hợp kiểm tra dữ liệu, tính toán thống kê và lựa chọn biểu đồ phù hợp với từng câu hỏi.

Bộ dữ liệu *Steel Plates Faults* được công bố trên UCI Machine Learning Repository gồm 27 đặc trưng và bảy nhãn lỗi, cung cấp một trường hợp thực hành phù hợp cho bài toán này [1]. Các biến vừa có dạng phân loại, vừa có dạng định lượng; việc phân tích vì thế cần kết hợp phép đếm, so sánh tỷ trọng và khảo sát phân bố. Bên cạnh đó, chất lượng đầu vào phải được kiểm tra trước khi vẽ biểu đồ, bởi một nhãn được viết theo nhiều cách, một dòng bị ghi nhận lặp lại hoặc một giá trị sai định dạng đều có thể làm thay đổi kết quả tổng hợp.

Đề tài *Trực quan hóa và phân tích dữ liệu lỗi bề mặt thép bằng Python* được lựa chọn nhằm thực hiện đầy đủ quá trình từ dữ liệu đầu vào đến kết quả có thể quan sát và đối chiếu. Python được sử dụng để thống nhất các thao tác đọc, làm sạch, tính toán và trực quan hóa trong cùng quy trình. Các biểu đồ tĩnh giúp trình bày kết quả trong báo cáo; dashboard bổ sung khả năng lọc và xem số liệu theo phạm vi do người sử dụng lựa chọn. Cách tổ chức này cũng giúp liên kết kiến thức lý thuyết với từng thao tác thực hành và kiểm tra lại kết quả khi chạy mã.

1.2 Mục tiêu và các câu hỏi phân tích

Mục tiêu của tiểu luận là xây dựng quy trình xử lý và trực quan hóa dữ liệu lỗi bề mặt thép bằng Python, trong đó mỗi bước xử lý có căn cứ, mỗi biểu đồ phục vụ một câu hỏi và các kết quả được tổ chức thành dashboard tương tác. Mục tiêu được cụ thể hóa thành bốn nội dung:

1. Khảo sát nguồn, cấu trúc và chất lượng dữ liệu để xác định yêu cầu xử lý.

2. Chuẩn hóa, làm sạch và đối chiếu dữ liệu; lưu dấu vết thay đổi và kiểm tra tính toàn vẹn sau xử lý.
3. Tạo biến, tính chỉ số mô tả và xây dựng biểu đồ để phân tích cơ cấu nhãn cùng các đặc trưng liên quan.
4. Xây dựng dashboard có bộ lọc, chỉ số tổng hợp, bảng và biểu đồ; kiểm thử chức năng và đối chiếu số liệu.

Các câu hỏi trong Bảng 1.1 định hướng nội dung khảo sát ở Chương 2 và phần thực hành ở Chương 3. Q0 kiểm tra điều kiện đầu vào, còn Q1–Q5 tập trung mô tả cơ cấu và đặc trưng của các nhóm lỗi.

Bảng 1.1. Các câu hỏi phân tích của đề tài

Mã	Câu hỏi phân tích
Q0	Những vấn đề nào được phát hiện trước khi tham chiếu giá trị UCI? Việc khôi phục có truy vết và đáp ứng điều kiện toàn vẹn sau xử lý không?
Q1	Cơ cấu bảy nhãn lỗi như thế nào? Mức tập trung và mất cân bằng giữa các nhãn ra sao?
Q2	Cơ cấu nhãn khác nhau thế nào giữa A300 và A400? Nhãn nào có trên 90% bản ghi tập trung ở cùng một dòng thép?
Q3	Phân bố độ sáng tối thiểu và tối đa khác nhau thế nào giữa các nhãn? Nhãn nào có khoảng P25–P75 của độ sáng tối thiểu không chồng lấn với mọi nhãn khác?
Q4	Phân bố độ dày khác nhau thế nào giữa các nhãn và giữa A300/A400 trong cùng nhãn?
Q5	Diện tích `Pixels_Areas` khác nhau thế nào giữa các nhãn về trung vị, IQR và giá trị ngoài râu boxplot?

Mốc trên 90% ở Q2 được sử dụng như một tiêu chí khám phá về mức tập trung trong mẫu [2]. Với Q3, việc không chồng lấn khoảng tứ phân vị chỉ phản ánh sự tách biệt của phần trung tâm phân bố. Những tiêu chí này được dùng để đọc và tổng hợp kết quả; không đại diện cho chuẩn chất lượng của ngành hoặc hiệu năng của một mô hình phân loại. Các tiêu chí cụ thể được giải thích khi xác định yêu cầu phân tích ở Chương 2.

1.3 Phạm vi thực hiện và sản phẩm đầu ra

Đối tượng phân tích là các bản ghi đã có nhãn lỗi. File dữ liệu thực hành được dùng làm đầu vào để khảo sát và xử lý; dữ liệu UCI cung cấp nguồn tham chiếu cho những bản ghi xác định được sự tương ứng. Việc dùng nguồn tham chiếu giúp lựa chọn giá trị khôi phục có căn cứ, còn kiểm tra nội tại giúp phát hiện vấn đề trước khi sửa. Hai hoạt động này được trình bày riêng để làm rõ vai trò của từng loại bằng chứng.

Phạm vi tiểu luận là mô tả và khám phá các liên hệ trong dữ liệu hiện có. Mẫu số của các tỷ trọng là số bản ghi lỗi trong phạm vi đang xét. Do thiếu tổng sản lượng, kết quả không cho biết tỷ lệ sản phẩm bị lỗi của một dòng thép. Đồng thời, chưa có đủ thông tin để coi mỗi bản ghi là một tấm thép độc lập hoặc để xác định nguyên nhân vận hành từ các liên hệ quan sát được. Các đơn vị chưa được metadata xác nhận được giữ theo thang của nguồn.

Biến `Production_Date` trong file thực hành là ngày mô phỏng, được chuẩn hóa để hoàn chỉnh hồ sơ bản ghi và không dùng suy luận xu hướng lỗi theo thời gian sản xuất. Phân tích thương mại qua UN Comtrade được bố trí ở phụ lục như nội dung bổ sung về thu thập và trực quan hóa qua API, độc lập với các câu hỏi về lỗi bề mặt. Tiểu luận tập trung vào xử lý dữ liệu, biểu đồ và dashboard; việc xây dựng mô hình dự báo là hướng mở rộng khi có điều kiện phù hợp.

Sản phẩm đầu ra gồm dữ liệu sạch, nhật ký và bảng kiểm tra; notebook cùng mã Python; các bảng thống kê, biểu đồ và nhận xét; dashboard tương tác cùng kết quả kiểm thử. Dữ liệu thô được lưu riêng để có thể đối chiếu, còn mã đầy đủ và hướng dẫn chạy lại được tổ chức trong phần bàn giao và phụ lục.

1.4 Cơ sở lý thuyết phục vụ xử lý và trực quan hóa

1.4.1 Chất lượng dữ liệu, làm sạch và kết hợp

Chất lượng dữ liệu được xem xét qua khả năng đáp ứng cấu trúc, kiểu, tính đầy đủ, tính nhất quán và các ràng buộc cần thiết cho phép tính. Ô thiếu làm giảm số quan sát có thể sử dụng; dòng trùng có thể làm tăng số đếm; nhãn không thống nhất chia một nhóm thành nhiều nhóm; sai định dạng số làm thay đổi giá trị hoặc khiến thao tác tính toán thất bại. Vì thế, bước khảo sát cần xác định vấn đề theo từng trường dữ liệu, thay vì chỉ kiểm tra quy mô của bảng.

Làm sạch bắt đầu từ các quy tắc có thể giải thích: chuẩn hóa biểu diễn nhãn, chuyển kiểu có kiểm tra, xác định tiêu chí trùng và kiểm tra quan hệ giữa các biến. Giá trị ngoài miền hợp lệ hoặc không phù hợp với quan hệ nội tại là dấu hiệu cần xem xét. Một giá trị lớn nhưng vẫn hợp lệ không tự động là lỗi; trường hợp này có thể được gắn cờ để quan sát thêm thay vì bị xóa.

Khi khôi phục từ bảng tham chiếu, khóa ghép phải xác định đúng bản ghi. Với phép ghép một–một, khóa phải duy nhất ở cả hai bảng và không được làm tăng số dòng ngoài dự kiến. Pandas hỗ trợ kiểm tra loại quan hệ ghép qua tham số `validate` [3]. Dữ liệu

sau ghép vẫn cần kiểm tra nhãn, số dòng và trường hợp chưa khớp. Mỗi thay đổi nên lưu dòng nguồn, tên trường, giá trị trước, giá trị sau và căn cứ xử lý. Nhật ký này giúp phân biệt kết quả phát hiện với thao tác sửa, đồng thời hỗ trợ kiểm tra lại dữ liệu sau khi xuất tệp.

1.4.2 Biến phái sinh và thống kê mô tả

Biến phái sinh được tính từ biến gốc để phục vụ kiểm tra hoặc làm rõ nội dung cần phân tích. Chẳng hạn, khoảng tọa độ được tính bằng hiệu cực đại và cực tiểu; khoảng độ sáng được tính bằng hiệu độ sáng lớn nhất và nhỏ nhất. Khi diện tích dương, logarit cơ số 10 có thể biểu diễn chênh lệch quy mô thuận tiện hơn. Nếu nguồn đã có một cột chứa cùng thông tin, cột tính lại chủ yếu phục vụ đối chiếu và không được coi là một đặc trưng độc lập mới.

Với n_g là số bản ghi của nhãn g và N là số bản ghi toàn tập, tỷ trọng của nhãn được tính bằng

$$p_g = \frac{n_g}{N} \times 100\%. \tag{1.1}$$

Sau khi sắp xếp nhãn theo số đếm giảm dần, tỷ trọng lũy kế đến vị trí k là $C_k = \sum_{j=1}^{k} p_{(j)}$. Chỉ số này cho biết mức tập trung của các nhãn đứng đầu.

Khi so sánh dòng thép, cần phân biệt hai mẫu số. Gọi $n_{g,s}$ là số bản ghi vừa thuộc nhãn g, vừa thuộc dòng thép s, ta có

$$p_{g|s} = \frac{n_{g,s}}{\sum_h n_{h,s}} \times 100\%, \qquad p_{s|g} = \frac{n_{g,s}}{\sum_t n_{g,t}} \times 100\%. \tag{1.2}$$

Đại lượng thứ nhất mô tả cơ cấu nhãn trong một dòng thép; đại lượng thứ hai mô tả một nhãn phân bố giữa các dòng thép. Dùng đúng mẫu số giúp tránh kết luận nhầm từ cùng một số đếm.

Đối với biến định lượng, trung vị mô tả vị trí trung tâm; P25 và P75 giới hạn phần trung tâm của phân bố; khoảng tứ phân vị được tính bằng $\mathrm{IQR} = \mathrm{P75} - \mathrm{P25}$. Trung vị và IQR phù hợp để trình bày nhóm có phân bố lệch hoặc có giá trị rất lớn. Độ lệch chuẩn mẫu bổ sung thông tin phân tán quanh trung bình:

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}, \qquad n \geq 2. \tag{1.3}$$

Các thống kê được đọc kèm cỡ mẫu n. Nhóm chỉ có một bản ghi chưa cho phép mô tả độ phân tán bằng độ lệch chuẩn mẫu.

Hệ số tương quan Pearson đo mức liên hệ tuyến tính giữa hai biến có phương sai khác không:

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}. \tag{1.4}$$

Trong đề tài, Pearson được dùng cho độ sáng tối thiểu và tối đa. Chỉ số này không đo trực tiếp khả năng phân biệt nhãn; vì vậy cần đọc cùng biểu đồ phân tán và thống kê theo nhóm.

1.4.3 Lựa chọn biểu đồ và nguyên tắc đọc kết quả

Biểu đồ được chọn theo nội dung cần so sánh. Thanh ngang giúp đọc thứ hạng và số lượng các nhãn; Pareto kết hợp số đếm giảm dần với tỷ trọng lũy kế để thể hiện mức tập trung. Cột nhóm so sánh số lượng giữa A300 và A400, còn cột chồng 100% thể hiện cơ cấu trong từng dòng thép. Hai cách biểu diễn bổ sung nhau vì tỷ trọng cao có thể xuất hiện trong một nhóm có tổng số bản ghi nhỏ.

Biểu đồ phân tán đặt một bản ghi tại vị trí xác định bởi hai biến định lượng. Màu sắc theo nhãn giúp quan sát vùng tập trung và phần chồng lấn. Khi nhiều điểm trùng hoặc gần nhau, có thể giảm kích thước và tăng độ trong suốt của điểm. Vùng trung tâm khác nhau là dấu hiệu để khảo sát tiếp; việc nhìn thấy các cụm trên hình chưa thay thế đánh giá một quy tắc phân loại.

Boxplot tóm tắt trung vị, khoảng tứ phân vị và các giá trị cực đoan, phù hợp khi so sánh phân bố giữa nhóm [4]. Với dạng boxplot dùng hệ số $1{,}5$, hai ngưỡng được xác định bởi

$$L = \mathrm{P25} - 1{,}5\,\mathrm{IQR}, \qquad U = \mathrm{P75} + 1{,}5\,\mathrm{IQR}. \tag{1.5}$$

Râu kéo đến các giá trị quan sát xa nhất còn nằm trong ngưỡng; các điểm bên ngoài được hiển thị riêng. Những điểm này chỉ thể hiện vị trí cực đoan theo quy tắc, không khẳng định dữ liệu sai. Hộp có thể thu thành đường nếu các tứ phân vị trùng nhau. Do đó, cần đọc boxplot cùng cỡ mẫu và bảng thống kê.

Khi diện tích trải trên nhiều mức quy mô, trục log giúp quan sát các nhóm nhỏ mà vẫn thể hiện được giá trị lớn. Trong cách trình bày của đề tài, các tứ phân vị và râu của boxplot được tính trên diện tích gốc, sau đó trục hiển thị chuyển sang log. Việc đổi trục không thay đổi kết quả tính toán trước đó. Chú thích phải chỉ rõ thang đo để người đọc hiểu rằng khoảng cách bằng nhau trên trục log biểu diễn cùng một tỷ số, không phải cùng một hiệu số.

Màu nhãn cần được dùng nhất quán giữa các hình; biểu đồ số đếm nên có trục bắt đầu từ 0; tiêu đề, trục, đơn vị hoặc thang nguồn phải rõ ràng. Mỗi hình được dẫn bằng một câu hỏi và được giải thích bằng số liệu cụ thể. Các nguyên tắc này giúp liên kết biểu đồ với nội dung phân tích, đồng thời hạn chế việc nhận xét chỉ theo cảm giác thị giác.

1.4.4 Dashboard tương tác và tính nhất quán sau lọc

Dashboard tổ chức các ô chỉ số tổng hợp (KPI), biểu đồ và bảng dữ liệu trên cùng giao diện, cho phép lựa chọn phạm vi quan sát bằng bộ lọc. Khi lọc theo dòng thép, nhãn hoặc khoảng độ dày, các thành phần phải được tính từ cùng tập con. Một KPI dùng toàn bộ dữ liệu trong khi biểu đồ dùng dữ liệu đã lọc sẽ làm người đọc đối chiếu sai phạm vi.

Vì vậy, trước khi hiển thị cần xác định tập con, tổng hợp các chỉ số và truyền cùng dữ liệu đó cho biểu đồ và bảng. Nếu tập con rỗng, giao diện phải thông báo trạng thái phù hợp. Cơ chế đọc lại nguồn cần kiểm tra dữ liệu mới trước khi thay bản đang sử dụng và thể hiện lỗi cập nhật khi có. Những yêu cầu này được cụ thể hóa ở Chương 2 và kiểm thử trên ứng dụng ở Chương 4.

1.5 Công cụ thực hiện và tài liệu liên quan

Python và Jupyter Notebook được dùng để tổ chức các bước xử lý cùng phần thuyết minh và đầu ra. Pandas quản lý bảng, đọc tệp, chuẩn hóa và tổng hợp nhóm; NumPy hỗ trợ phép tính số và kiểm tra sai lệch. Matplotlib được dùng cho các hình tĩnh, còn Plotly và Streamlit phục vụ biểu đồ cùng giao diện tương tác [5, 6]. Requests và JSON hỗ trợ thu thập, đọc và lưu phản hồi API. Các công cụ này tạo thành luồng xử lý thống nhất từ đầu vào đến sản phẩm; phiên bản và cách cài đặt được ghi trong phụ lục.

UCI cung cấp hồ sơ của bộ *Steel Plates Faults* và là nguồn trích dẫn dữ liệu [1]. Một tài liệu liên quan của Kharal trình bày cách kết hợp phân loại và các công cụ giải thích mô hình trên dữ liệu lỗi thép [7]. Tài liệu đó cho thấy cùng một tập dữ liệu có thể được khai thác theo mục tiêu dự báo và giải thích mô hình. Tiểu luận hiện tại tập trung vào kiểm tra dữ liệu, thống kê mô tả và trực quan hóa; vì vậy đầu ra được xem xét theo độ nhất quán của xử lý, khả năng trả lời câu hỏi và chức năng dashboard.

Các kiến thức trong chương này là căn cứ cho phần thực hành tiếp theo. Chương 2 khảo sát tập dữ liệu, ghi nhận vấn đề và xác định yêu cầu; Chương 3 thực hiện xử lý, tính toán và vẽ biểu đồ bằng Python; Chương 4 xây dựng và kiểm thử dashboard từ dữ liệu cùng các kết quả đã tạo.

Tài liệu tham khảo

[1] M. Buscema, S. Terzi và W. Tastle, *Steel Plates Faults* [Bộ dữ liệu], UCI Machine Learning Repository, 2010. DOI: 10.24432/C5J88N.

[2] Đinh Nhật Anh, Nguyễn Thị Phương và Nguyễn Lê Ngọc Khôi, *Phân tích nguy cơ xảy ra lỗi trong dây chuyền sản xuất thép*, tài liệu đọc, không ghi năm, mục V.3. Tệp: [Reading]-Data-Analytics-in-Manufacturing.pdf.

[3] pandas development team, *Merge, join, concatenate and compare*, tài liệu pandas. https://pandas.pydata.org/docs/user_guide/merging.html. Truy cập ngày 11/10/2026.

[4] NIST/SEMATECH, *e-Handbook of Statistical Methods*, mục 1.3.3.7: Box Plot. https://www.itl.nist.gov/div898/handbook/eda/section3/boxplot.htm. Truy cập ngày 11/10/2026.

[5] Matplotlib development team, *Matplotlib: Visualization with Python*. https://matplotlib.org/stable/. Truy cập ngày 11/10/2026.

[6] Streamlit, *Streamlit Documentation*. https://docs.streamlit.io/. Truy cập ngày 11/10/2026.

[7] A. Kharal, *Explainable Artificial Intelligence Based Fault Diagnosis and Insight Harvesting for Steel Plates Manufacturing*, arXiv:2008.04448, bản v1, 2020. https://arxiv.org/abs/2008.04448.