Mục lục

Mục lục i

Danh mục hình vẽ iii

Danh mục bảng biểu iv

Thuật ngữ và từ viết tắt v

Phần mở đầu vi
1. Bối cảnh và lý do lựa chọn đề tài . . . vi
2. Mục tiêu thực hiện . . . vi
3. Đối tượng và phạm vi thực hiện . . . vii
4. Các câu hỏi phân tích . . . vii
5. Giá trị của đề tài và sản phẩm đầu ra . . . viii
6. Bố cục của báo cáo . . . viii

1 Tổng quan bài toán và cơ sở lý thuyết 1
1.1 Tổng quan bài toán phân tích lỗi bề mặt thép . . . 1
1.1.1 Đặc điểm dữ liệu lỗi bề mặt thép . . . 1
1.1.2 Vai trò của phân tích khám phá và trực quan hóa . . . 1
1.2 Cơ sở về chất lượng và xử lý dữ liệu . . . 2
1.2.1 Dữ liệu thiếu, trùng lặp và không nhất quán . . . 2
1.2.2 Chuẩn hóa, kết hợp và kiểm tra dữ liệu . . . 2
1.3 Cơ sở thống kê mô tả và tạo biến . . . 3
1.3.1 Các chỉ số thống kê sử dụng . . . 3
1.3.2 Biến phái sinh và phép biến đổi logarit . . . 3
1.4 Cơ sở lựa chọn biểu đồ và dashboard . . . 4
1.4.1 Biểu đồ cơ cấu và so sánh nhóm . . . 4
1.4.2 Biểu đồ phân bố và mối liên hệ . . . 4
1.4.3 Dashboard tương tác . . . 5
1.5 Tiểu kết chương . . . 5

2 Khảo sát dữ liệu, công cụ và yêu cầu thực hiện 6
2.1 Nguồn và cấu trúc dữ liệu . . . 6
2.1.1 Tệp dữ liệu thực hành . . . 6
2.1.2 Nguồn tham chiếu UCI . . . 6
2.1.3 Nhóm biến và giới hạn thông tin . . . 7
2.2 Khảo sát tình trạng dữ liệu trước xử lý . . . 7
2.3 Công cụ và môi trường thực hiện . . . 8

2.3.1 Công cụ xử lý và trực quan hóa 8
2.3.2 Căn cứ lựa chọn Python 8
2.4 Yêu cầu phân tích và tiêu chí đọc kết quả 9
2.4.1 Đầu ra cho Q0–Q5 9
2.4.2 Yêu cầu dashboard và kiểm thử 10
2.5 Định hướng thực hiện và tiểu kết chương 10

Tài liệu tham khảo **11**

Danh mục hình vẽ

1.1 Mối liên hệ giữa nền tảng lý thuyết và các phần thực hành 2

Danh mục bảng biểu

1.1 Lựa chọn biểu đồ theo nội dung cần phân tích 4

2.1 Quy mô và vai trò của hai nguồn dữ liệu 6
2.2 Tình trạng đầu vào và yêu cầu xử lý tương ứng 8
2.3 Đầu ra và trọng tâm đọc kết quả cho Q0–Q5 9

Thuật ngữ và từ viết tắt

Ký hiệu	Tên đầy đủ	Ý nghĩa trong báo cáo
UCI	University of California, Irvine	Kho dữ liệu cung cấp bộ Steel Plates Faults và nguồn tham chiếu.
EDA	Exploratory Data Analysis	Phân tích khám phá dữ liệu.
IQR	Interquartile Range	Khoảng tứ phân vị, bằng P75 trừ P25.
SD	Standard Deviation	Độ lệch chuẩn; bài sử dụng độ lệch chuẩn mẫu khi tổng hợp.
KPI	Key Performance Indicator	Chỉ số tổng hợp hiển thị trên dashboard; không mặc định là chỉ tiêu vận hành nhà máy.
API	Application Programming Interface	Giao diện lập trình ứng dụng, dùng khi truy vấn nguồn dữ liệu bổ sung.
CSV	Comma-Separated Values	Định dạng văn bản phân cách các trường, dùng lưu dữ liệu dạng bảng.
JSON	JavaScript Object Notation	Định dạng trao đổi và lưu thông tin có cấu trúc.
XLSX	Office Open XML Spreadsheet	Định dạng tệp bảng tính đầu vào; được đọc và xử lý bằng Python.
P25, P75	25th, 75th Percentiles	Phân vị 25% và 75%, mô tả phần trung tâm của phân bố.
N	Number of observations	Số bản ghi của toàn tập hoặc của nhóm đang xét.

Trong báo cáo, *dashboard* được hiểu là giao diện tổng hợp dữ liệu có bộ lọc, chỉ số, biểu đồ và bảng. A300 và A400 được giữ nguyên theo tên hai dòng thép trong dữ liệu; chúng không được mở rộng thành tiêu chuẩn vật liệu khi metadata chưa xác nhận.

Phần mở đầu

1. Bối cảnh và lý do lựa chọn đề tài

Một biểu đồ có thể làm nổi bật một nhóm lỗi chỉ trong vài giây, nhưng độ tin cậy của nhận xét phụ thuộc vào những việc đã được thực hiện trước khi vẽ. Nhãn được viết không thống nhất có thể làm một nhóm bị tách thành nhiều nhóm; bản ghi trùng làm thay đổi số đếm; giá trị thiếu hoặc bất thường ảnh hưởng đến các đại lượng thống kê. Với dữ liệu lỗi bề mặt thép, kiểm tra đầu vào và lựa chọn cách biểu diễn vì thế cần được xem xét trong cùng một quy trình.

Bộ dữ liệu *Steel Plates Faults* trên UCI Machine Learning Repository gồm 1.941 bản ghi, 27 đặc trưng và bảy nhãn lỗi [1]. Các đặc trưng phản ánh những khía cạnh khác nhau của bản ghi, từ tọa độ, diện tích và độ sáng đến dòng thép và độ dày. Khi chỉ đọc bảng, người phân tích khó đồng thời nhận ra nhãn nào xuất hiện nhiều, phân bố đặc trưng khác nhau ra sao và những nhóm nào cần được xem xét kỹ hơn. Biểu đồ giúp tổ chức các thông tin đó thành những góc nhìn có thể đối chiếu.

Đề tài *Trực quan hóa và phân tích dữ liệu lỗi bề mặt thép bằng Python* được lựa chọn để thực hiện quá trình từ khảo sát đầu vào đến trình bày kết quả. Quy tắc xử lý, công thức tính và thao tác vẽ được ghi trong mã Python để chạy lại và kiểm tra. Biểu đồ tĩnh phục vụ phần phân tích; dashboard bổ sung khả năng lọc và xem số liệu theo nhóm. Mỗi thao tác được lựa chọn theo vấn đề cụ thể của dữ liệu.

2. Mục tiêu thực hiện

Mục tiêu chung là xây dựng quy trình xử lý và trực quan hóa dữ liệu lỗi bề mặt thép bằng Python, sau đó tổ chức kết quả thành bảng, biểu đồ và dashboard tương tác. Mục tiêu này được cụ thể hóa thành bốn nội dung có thể đối chiếu với sản phẩm đầu ra.

Trước hết, bài khảo sát nguồn, cấu trúc và chất lượng đầu vào. Tiếp theo, dữ liệu được chuẩn hóa, làm sạch và ghép nguồn tham chiếu có kiểm tra, có nhật ký. Bài sử dụng dữ liệu sau xử lý để tạo biến, tính chỉ số và vẽ biểu đồ cho từng câu hỏi. Cuối cùng, các kết quả được tổ chức thành dashboard; chức năng được kiểm thử và số liệu được đối chiếu với quy trình phân tích.

Mỗi mục tiêu được đối chiếu với đầu ra tương ứng. Người đọc có thể kiểm tra kết quả qua dữ liệu, nhật ký, bảng và hình, cùng bằng chứng về cách tính.

3. Đối tượng và phạm vi thực hiện

Đối tượng phân tích là các bản ghi có nhãn lỗi trong bộ *Steel Plates Faults* và tệp thực hành tương ứng. Mỗi dòng được xem là một đơn vị quan sát của bài; dữ liệu hiện có chưa đủ để mặc định mỗi dòng là một tấm thép độc lập. Tệp thực hành được dùng làm đầu vào cho các bước khảo sát và làm sạch; nguồn UCI cung cấp metadata và giá trị tham chiếu cho những bản ghi đã xác nhận tương ứng.

Phạm vi nội dung gồm chất lượng dữ liệu, cơ cấu bảy nhãn lỗi và sự khác nhau về dòng thép A300/A400, độ sáng, độ dày, diện tích. Các kết quả mang tính mô tả và khám phá trong tập quan sát. Do chưa có tổng sản lượng, đầy đủ biến vận hành và định danh sản phẩm, bài chưa xác định tỷ lệ sản phẩm lỗi hoặc nguyên nhân gây lỗi. Những thang đo chưa có đơn vị được xác nhận sẽ được giữ theo giá trị của nguồn.

Cột `Production_Date` chứa ngày mô phỏng, được chuẩn hóa để quản lý hồ sơ dữ liệu; cột này không dùng để suy ra xu hướng sản xuất thực tế. Phân tích thương mại qua UN Comtrade, mang mã Q6 trong notebook, là nội dung bổ sung ở phụ lục. Nguồn thương mại không có khóa liên hệ với các bản ghi lỗi nên được phân tích riêng. Toàn bộ xử lý và trực quan hóa của đề tài sử dụng Python; XLSX là định dạng tệp đầu vào.

4. Các câu hỏi phân tích

Các câu hỏi được tổ chức từ kiểm tra dữ liệu đến mô tả cơ cấu và so sánh đặc trưng. Q0 kiểm tra điều kiện đầu vào và kết quả xử lý; Q1–Q5 định hướng nội dung phân tích chính.

Mã	Câu hỏi phân tích
Q0	Những vấn đề nào được phát hiện trước khi tham chiếu giá trị UCI; việc khôi phục có truy vết và dữ liệu sau xử lý có đáp ứng các điều kiện toàn vẹn không?
Q1	Cơ cấu bảy nhãn lỗi như thế nào; mức tập trung và mất cân bằng giữa các nhãn ra sao?
Q2	Cơ cấu nhãn khác nhau thế nào giữa A300/A400; nhãn nào có trên 90% bản ghi tập trung ở cùng một dòng thép?
Q3	Phân bố độ sáng tối thiểu/tối đa khác nhau thế nào giữa các nhãn; nhãn nào có khoảng P25–P75 của độ sáng tối thiểu không chồng lấn với mọi nhãn khác?
Q4	Phân bố độ dày khác nhau thế nào giữa các nhãn và giữa A300/A400 trong cùng nhãn?
Q5	Diện tích `Pixels_Areas` khác nhau thế nào giữa các nhãn về trung vị, IQR và các giá trị ngoài râu boxplot?

Mốc trên 90% ở Q2 được sử dụng như một mốc khám phá theo tài liệu đọc, mục V.3 [2]. Tiêu chí không chồng lấn IQR ở Q3 giúp diễn đạt sự khác nhau của phần trung tâm phân bố; tiêu chí này được bổ sung trong quá trình phân tích, không phải giả thuyết xác định trước. Mẫu số, đầu ra và cách đọc kết quả của từng câu hỏi được cụ thể hóa trong phần yêu cầu phân tích ở Chương 2.

5. Giá trị của đề tài và sản phẩm đầu ra

Giá trị học tập của đề tài nằm ở việc nối sáu bước môn học thành một quá trình rõ đầu vào và đầu ra. Kiến thức về dữ liệu thiếu, khóa ghép, tỷ trọng, tứ phân vị và thang log giúp giải thích lựa chọn thực hành, kết quả và giới hạn của phương pháp.

Về ứng dụng, bảng và biểu đồ giúp người đọc nhận diện cơ cấu nhãn, đối chiếu các nhóm và tìm những đặc điểm cần kiểm tra thêm. Dashboard cho phép lựa chọn phạm vi quan sát mà vẫn giữ khả năng xem lại số liệu. Những giá trị này được đánh giá qua tính đúng đắn và khả năng hoạt động của sản phẩm; hiệu quả hỗ trợ quyết định trong nhà máy cần một phép đánh giá thực tế riêng.

Sản phẩm đầu ra gồm notebook Python, dữ liệu sau xử lý, nhật ký chuẩn hóa và khôi phục, bảng thống kê, hình trực quan, dashboard cùng kết quả kiểm thử. Báo cáo trình bày những đoạn mã cần thiết để giải thích cách làm; mã đầy đủ, từ điển dữ liệu và các bảng dài được tổ chức trong phụ lục.

6. Bố cục của báo cáo

Ngoài phần mở đầu, kết luận, tài liệu tham khảo và phụ lục, báo cáo có bốn chương. Chương 1 trình bày bài toán và cơ sở lý thuyết. Chương 2 khảo sát nguồn, cấu trúc, tình trạng dữ liệu, công cụ và yêu cầu thực hiện.

Chương 3 trình bày cách xử lý, tạo biến, xây dựng biểu đồ và dashboard bằng Python. Chương 4 phân tích kết quả, trả lời các câu hỏi, trình bày sản phẩm, kiểm thử và thảo luận. Mạch bài đi từ kiến thức đến vấn đề của dữ liệu, thao tác thực hiện và bằng chứng thu được.

CHƯƠNG 1

Tổng quan bài toán và cơ sở lý thuyết

1.1 Tổng quan bài toán phân tích lỗi bề mặt thép

1.1.1 Đặc điểm dữ liệu lỗi bề mặt thép

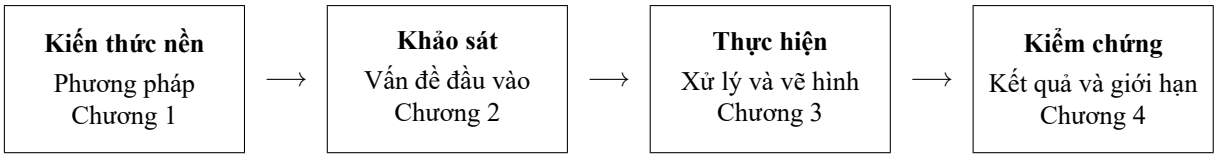
Dữ liệu lỗi bề mặt thép mô tả những đặc điểm quan sát được tại vùng lỗi: vị trí, kích thước, diện tích, độ sáng và các thông tin liên quan đến dòng thép, độ dày. Một đặc trưng riêng lẻ chỉ cung cấp một góc nhìn. Diện tích phản ánh quy mô vùng được ghi nhận; độ sáng mô tả đặc điểm ảnh; dòng thép tạo điều kiện so sánh giữa các nhóm. Kết hợp các đặc trưng giúp đặt từng quan sát vào bối cảnh của nhóm tương ứng.

Bộ *Steel Plates Faults* trên UCI cung cấp 27 đặc trưng và bảy nhãn lỗi [1]. Các biến định lượng phù hợp với phân tích vị trí trung tâm, độ phân tán và mối liên hệ; nhãn lỗi và dòng thép phù hợp với phép đếm, tỷ trọng và phân nhóm. Cần giữ rõ đơn vị quan sát: số bản ghi mang một nhãn chưa mặc nhiên là số tấm thép độc lập. Mỗi phép tổng hợp cần được diễn giải theo thông tin nguồn cung cấp.

1.1.2 Vai trò của phân tích khám phá và trực quan hóa

Phân tích khám phá dữ liệu (EDA) là quá trình khảo sát cấu trúc, phân bố và các quan hệ đáng chú ý trước khi đưa ra kết luận. Trong bài toán này, EDA giúp nhận diện mức tập trung của nhãn, khác biệt giữa nhóm và những giá trị cần kiểm tra. Biểu đồ hỗ trợ quan sát nhanh; bảng thống kê cung cấp căn cứ định lượng để đối chiếu. Hai hình thức bổ sung nhau: một vùng có vẻ tách biệt trên hình vẫn cần được đọc cùng khoảng tứ phân vị, cỡ mẫu và mức chồng lấn.

Cùng bộ dữ liệu lỗi thép, Kharal trình bày hướng phân loại và giải thích mô hình bằng các công cụ trí tuệ nhân tạo có khả năng giải thích [8]. Với phân tích mô tả, trọng tâm là xác định dữ liệu đang thể hiện điều gì và bằng chứng có giới hạn ra sao. Hình 1.1 thể hiện mạch kết nối lý thuyết với khảo sát, thực hiện và kiểm chứng.



Hình 1.1. Mối liên hệ giữa nền tảng lý thuyết và các phần thực hành

1.2 Cơ sở về chất lượng và xử lý dữ liệu

1.2.1 Dữ liệu thiếu, trùng lặp và không nhất quán

Chất lượng dữ liệu được xem xét theo yêu cầu của phép phân tích. Ô thiếu làm giảm số quan sát dùng được cho một đặc trưng; dòng trùng có thể làm tăng số đếm; nhãn biểu diễn không thống nhất chia cùng một nhóm thành nhiều nhóm. Sai kiểu hoặc sai định dạng số còn có thể khiến phép tính thất bại hay sử dụng giá trị ngoài dự kiến. Vì vậy, khảo sát cần thực hiện theo từng cột và từng quy tắc, không chỉ dựa vào số dòng của bảng.

Cần phân biệt dấu hiệu nghi ngờ với bằng chứng sai dữ liệu. Một giá trị vi phạm miền hợp lệ hoặc quan hệ giữa các biến cần được kiểm tra; một giá trị lớn nhưng vẫn hợp lệ có thể phản ánh trường hợp hiếm. Điểm nằm ngoài râu boxplot cũng chưa đủ căn cứ để xóa. Nếu chưa xác định được nguyên nhân, gắn cờ và giữ dấu vết là cách xử lý phù hợp hơn việc thay đổi giá trị chỉ để làm phân bố trông đều hơn.

1.2.2 Chuẩn hóa, kết hợp và kiểm tra dữ liệu

Chuẩn hóa đưa những biểu diễn tương đương về cùng dạng, chẳng hạn nhãn có khoảng trắng thừa hoặc cách viết khác nhau đã được xác nhận. Tiêu chí trùng cần được xác định theo các trường có ý nghĩa, đồng thời ghi rõ dòng giữ và dòng loại. Khi chuyển sang kiểu số, phải theo dõi giá trị không chuyển được; nếu chúng bị đổi thành ô thiếu, số thiếu tăng lên cần có lời giải thích.

Kết hợp nguồn tham chiếu chỉ có căn cứ khi xác định đúng bản ghi tương ứng. Với quan hệ một–một, khóa ghép phải đầy đủ và duy nhất ở cả hai bảng; sau ghép cần kiểm tra số dòng, tỷ lệ khớp và bản ghi chưa tìm thấy. Tham số `validate` của phép ghép Pandas hỗ trợ kiểm tra quan hệ này [3]. Dấu vết xử lý cần gồm trường thay đổi, giá trị cũ, giá trị mới và căn cứ. Đặc biệt, phát hiện vấn đề, chọn giá trị sửa và kiểm tra sau sửa là ba hoạt động riêng: độ khớp với chính nguồn đã dùng để khôi phục xác nhận thao tác, nhưng không phải phép đánh giá độc lập về khả năng phát hiện sai sót.

1.3 Cơ sở thống kê mô tả và tạo biến

1.3.1 Các chỉ số thống kê sử dụng

Số đếm cho biết quy mô của nhóm, còn tỷ trọng cho biết vị trí của nhóm trong tập đang xét. Gọi n_g là số bản ghi thuộc nhãn g và N là tổng số bản ghi, tỷ trọng là $p_g = 100n_g/N$ (%). Sau khi sắp xếp số đếm giảm dần, tỷ trọng lũy kế $C_k = \sum_{j=1}^{k} p_{(j)}$ biểu thị mức tập trung ở k nhãn đầu. Các đại lượng này chỉ có ý nghĩa khi mẫu số được xác định rõ.

Khi phân nhóm theo dòng thép, cùng một số đếm có thể tạo ra hai tỷ trọng khác nhau. Với $n_{g,s}$ là số bản ghi thuộc nhãn g và dòng thép s, ta có

$$p_{g|s} = \frac{n_{g,s}}{\sum_h n_{h,s}} \times 100\%, \qquad p_{s|g} = \frac{n_{g,s}}{\sum_t n_{g,t}} \times 100\%. \tag{1.1}$$

Tỷ trọng thứ nhất mô tả cơ cấu nhãn trong một dòng thép; tỷ trọng thứ hai mô tả một nhãn phân bố giữa các dòng thép. Nếu mẫu chỉ chứa bản ghi có lỗi, cả hai tỷ trọng đều chưa cho biết xác suất phát sinh lỗi trong sản xuất, bởi chưa có tổng số đơn vị được kiểm tra làm mẫu số.

Đối với biến định lượng, trung vị mô tả vị trí trung tâm; P25 và P75 giới hạn phần trung tâm của phân bố. Khoảng tứ phân vị là $\mathrm{IQR} = \mathrm{P75} - \mathrm{P25}$, phù hợp để đọc độ phân tán khi phân bố lệch. Độ lệch chuẩn mẫu bổ sung thông tin về mức phân tán quanh trung bình [4]:

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}, \qquad n \geq 2. \tag{1.2}$$

Ở đây, n là số giá trị hợp lệ thực sự tham gia phép tính. Nhóm chỉ có một quan sát chưa xác định được độ lệch chuẩn mẫu; ô thiếu cũng khiến cỡ mẫu của từng đặc trưng khác tổng số dòng. Vì vậy, bảng thống kê cần ghi n thay vì để người đọc tự suy đoán.

Hệ số Pearson đo mức liên hệ tuyến tính giữa hai biến định lượng có phương sai khác không [5]. Giá trị gần 1 hoặc -1 thể hiện liên hệ tuyến tính mạnh theo chiều tương ứng; gần 0 chưa loại trừ quan hệ phi tuyến. Pearson của độ sáng tối thiểu và tối đa không đo khả năng phân loại nhãn. Nó cần được đọc cùng scatter và thống kê theo nhóm, vì một hệ số chung có thể che khuất khác biệt bên trong các nhóm.

1.3.2 Biến phái sinh và phép biến đổi logarit

Biến phái sinh được tạo để phục vụ phép kiểm tra hoặc cách đọc kết quả. Các cờ nhị phân có thể được tổng hợp thành một biến phân loại khi cấu trúc cờ hợp lệ; hiệu cực đại và cực tiểu mô tả khoảng biến thiên. Những phép tính này phải có điều kiện áp dụng và

được đối chiếu với metadata. Nếu nguồn đã chứa cùng thông tin, cột tính lại có giá trị kiểm tra nhưng không trở thành đặc trưng độc lập mới.

Với $x > 0$, phép biến đổi $z = \log_{10}(x)$ giúp biểu diễn dải giá trị rộng. Cần phân biệt tính thống kê trên z với chỉ đổi trục hiển thị sang log. Trong cách dựng boxplot diện tích của đề tài, tứ phân vị và râu được tính trên giá trị gốc, sau đó mới đổi trục. Các giá trị không dương phải được kiểm tra trước khi dùng thang log; tên cột và công thức cụ thể được trình bày ở phần thực hiện.

1.4 Cơ sở lựa chọn biểu đồ và dashboard

1.4.1 Biểu đồ cơ cấu và so sánh nhóm

Thanh ngang thuận tiện khi cần đọc thứ hạng và nhãn dài. Pareto kết hợp số đếm giảm dần với tỷ trọng lũy kế để thể hiện mức tập trung, nhưng tần suất cao chưa đồng nghĩa mức thiệt hại cao. Cột nhóm so sánh số lượng giữa các dòng thép; cột 100% so sánh cơ cấu bằng cách đưa mỗi nhóm về cùng tổng tỷ trọng. Khi dùng cột 100%, cần giữ thông tin tổng số quan sát vì nhóm nhỏ và nhóm lớn có thể trông giống nhau về tỷ lệ.

Bảng 1.1 tổng hợp căn cứ lựa chọn biểu đồ. Khi xây dựng hình, cần tổ chức trục, chú thích và thang hiển thị phù hợp [6]; màu của cùng một nhãn được giữ nhất quán giữa các hình. Trục của cột số đếm nên bắt đầu từ 0 để độ dài cột phản ánh đúng chênh lệch. Khi đơn vị chưa được nguồn xác nhận, nhãn trục giữ thang dữ liệu thay vì tự gán một đơn vị vật lý.

Bảng 1.1. Lựa chọn biểu đồ theo nội dung cần phân tích

Nội dung	Biểu đồ phù hợp	Thông tin cần đọc kèm
Cơ cấu và mức tập trung của nhãn	Thanh ngang, Pareto	Tổng số bản ghi, tỷ trọng lũy kế
So sánh nhãn giữa dòng thép	Cột nhóm, cột 100%	Tổng từng nhóm, mẫu số tỷ trọng
Liên hệ giữa hai đặc trưng	Scatter, màu theo nhãn	Mức chồng lấn, số quan sát
Phân bố độ dày theo nhóm	Boxplot	Trung vị, IQR và cỡ mẫu
Diện tích có dải giá trị rộng	Boxplot, trục log	Thang hiển thị, giá trị gốc và điểm ngoài râu

1.4.2 Biểu đồ phân bố và mối liên hệ

Scatter đặt mỗi quan sát tại vị trí xác định bởi hai biến định lượng. Màu theo nhãn cho phép quan sát vùng tập trung và mức chồng lấn. Khi điểm chồng lên nhau, giảm kích

thước và tăng độ trong suốt giúp hình dễ đọc hơn, nhưng không thay thế thông tin về cỡ mẫu. Một cụm có vẻ tách biệt cần được đối chiếu bằng thống kê; hình ảnh riêng lẻ chưa chứng minh hiệu năng phân loại.

Boxplot tóm tắt phân bố qua trung vị, hai tứ phân vị và râu [4]. Với hệ số $1{,}5$, hàng rào dưới và trên được xác định bởi

$$L = \mathrm{P25} - 1{,}5\,\mathrm{IQR}, \qquad U = \mathrm{P75} + 1{,}5\,\mathrm{IQR}. \tag{1.3}$$

Râu kết thúc tại các giá trị quan sát xa nhất còn nằm trong $[L, U]$, không mặc nhiên trùng với hai hàng rào. Điểm bên ngoài được hiển thị riêng theo quy tắc này; chúng chưa được xác định là dữ liệu sai. Nếu các tứ phân vị bằng nhau, hộp có thể thu thành đường, nên cần đọc cùng bảng và cỡ mẫu. Các tham số dựng hình phải thống nhất với quy tắc được mô tả.

Với boxplot diện tích trên trục log, khoảng cách bằng nhau thể hiện cùng một tỷ số, không phải cùng một hiệu số. Quy tắc IQR áp dụng toàn tập và quy tắc tính riêng từng nhóm cũng có thể gắn cờ những quan sát khác nhau. Vì vậy, chú thích cần nêu phạm vi tính và thang hiển thị; việc giữ hay loại bản ghi phải dựa trên kiểm tra dữ liệu, thay vì dựa riêng vào vị trí của điểm trên hình.

1.4.3 Dashboard tương tác

Dashboard tổ chức bộ lọc, chỉ số tổng hợp (KPI), biểu đồ và bảng trên cùng giao diện; các thành phần tương tác có thể được triển khai bằng Streamlit [7]. Khi lọc theo dòng thép, nhãn hoặc độ dày, các thành phần của cùng phần phân tích phải dùng cùng tập con. Tỷ trọng cần xác định lại mẫu số sau lọc và ghi rõ ý nghĩa.

Tập con rỗng cần có thông báo phù hợp. Chức năng tải dữ liệu phải xuất đúng phạm vi đã mô tả; nguồn mới được kiểm tra trước khi sử dụng. Kiểm thử cần đối chiếu số đếm, bảng và hình trong các tình huống cụ thể. Kết quả kiểm thử chức năng cung cấp bằng chứng về hoạt động của ứng dụng; hiệu quả sử dụng cần có phép đo riêng.

1.5 Tiểu kết chương

Chất lượng dữ liệu, mẫu số, cỡ mẫu và lựa chọn biểu đồ quyết định phạm vi diễn giải. Những căn cứ vừa trình bày được dùng để khảo sát đầu vào ở Chương 2, triển khai bằng Python ở Chương 3 và đối chiếu kết quả ở Chương 4.

CHƯƠNG 2

Khảo sát dữ liệu, công cụ và yêu cầu thực hiện

2.1 Nguồn và cấu trúc dữ liệu

2.1.1 Tệp dữ liệu thực hành

Trang tính chính *Faults (2)* trong tệp XLSX gồm 1.961 dòng và 29 cột: 27 đặc trưng, cột ngày `Production_Date` và cột nhãn `Faults`; trang *Mo ta data* cung cấp phần mô tả. Bảng chính được dùng để thực hiện quy trình khảo sát, làm sạch và trực quan hóa. XLSX là định dạng lưu trữ; các thao tác đọc, xử lý và vẽ hình được thực hiện bằng Python.

Số dòng ban đầu chưa thể dùng ngay làm mẫu số phân tích: bảng có ô thiếu, nhãn chưa thống nhất và dòng trùng. Bản gốc cần được giữ riêng; dữ liệu làm việc phải có dấu vết thay đổi. Cột ngày là thông tin mô phỏng bổ sung, không phải thời điểm sản xuất do UCI cung cấp.

2.1.2 Nguồn tham chiếu UCI

Nguồn tham chiếu là bộ *Steel Plates Faults* do Buscema, Terzi và Tastle công bố trên UCI Machine Learning Repository năm 2010, với DOI `10.24432/C5J88N` và giấy phép CC BY 4.0 [1]. Bộ dữ liệu có 1.941 bản ghi và 27 đặc trưng. Tệp nguồn biểu diễn bảy nhãn bằng bảy cột nhị phân, nên bảng đọc vào gồm 34 cột. Bảng 2.1 phân biệt vai trò của hai nguồn.

Bảng 2.1. Quy mô và vai trò của hai nguồn dữ liệu

Nguồn	Quy mô đầu vào	Vai trò
Tệp thực hành	1.961 dòng; 29 cột	Đầu vào cần khảo sát và xử lý; có nhãn văn bản và ngày mô phỏng.
UCI	1.941 dòng; 34 cột	Cung cấp cấu trúc đặc trưng, nhãn nhị phân và giá trị tham chiếu.

Bốn tọa độ `X_Minimum`, `X_Maximum`, `Y_Minimum` và `Y_Maximum` là khóa ghép dự kiến. Trước khi sử dụng, cần kiểm tra tính đầy đủ, giá trị nguyên, tính duy nhất sau xử lý trùng và mức khớp một–một giữa hai bảng. Ràng buộc ghép được kiểm tra

bằng Pandas [3]. Khi khóa chưa đạt yêu cầu, không được tự chọn một dòng tham chiếu để điền giá trị. UCI cung cấp căn cứ khôi phục; độ khớp sau khôi phục chỉ xác nhận thao tác theo nguồn này.

2.1.3 Nhóm biến và giới hạn thông tin

Các đặc trưng gồm tọa độ, kích thước và diện tích; độ sáng; dòng thép và độ dày; các chỉ số hình học, định hướng và logarit. `Pixels_Areas` mô tả diện tích; `Minimum_of_Luminosity` và `Maximum_of_Luminosity` hỗ trợ so sánh độ sáng. Hai cờ A300/A400 cần được kiểm tra trước khi tổng hợp thành dòng thép. Giữ thang số theo nguồn, chưa tự gán đơn vị khi metadata chưa xác nhận. Đặc trưng `LogOfAreas` đã có trong nguồn, nên cột logarit diện tích tính thêm cần được kiểm tra sự trùng thông tin.

Bảy nhãn gồm `Pastry`, `Z_Scratch`, `K_Scatch`, `Stains`, `Dirtiness`, `Bumps` và `Other_Faults`. Cột `K_Scratch` trong bản CSV tham chiếu cần được ánh xạ về `K_Scatch` theo nhãn gốc đã kiểm tra. `Other_Faults` là nhãn gộp, chưa cho biết thành phần bên trong. Thiếu sản lượng, định danh tấm/cuộn và biến vận hành đầy đủ, dữ liệu chưa cho phép xác định tỷ lệ sản phẩm lỗi. Nguồn UN Comtrade không có khóa liên hệ với các bản ghi lỗi, nên chỉ được trình bày độc lập.

2.2 Khảo sát tình trạng dữ liệu trước xử lý

Khảo sát đầu vào cần tách vấn đề của ô, dòng và nhãn. Bảng 2.2 ghi nhận tình trạng tại thời điểm trước xử lý và yêu cầu phát sinh; đây chưa phải bảng kết quả làm sạch.

Kiểu `object` trong bảng kiểm kê xuất phát từ lựa chọn đọc dữ liệu để giữ biểu diễn gốc; chưa thể dựa riêng vào kiểu này để kết luận mọi ô đều là chuỗi. Chẳng hạn, `X_Perimeter` chứa cả số nguyên và chuỗi biểu diễn số. Vấn đề cần giải quyết là đưa các giá trị tương đương về cùng kiểu tính toán và theo dõi những giá trị không chuyển được.

Số 70 là tổng ô thiếu trong 27 đặc trưng ban đầu, nằm ở `Pixels_Areas`, `Steel_Plate_Thickness`, `Log_Y_Index` và `Orientation_Index`. Tính thống kê trực tiếp khiến cỡ mẫu diện tích và độ dày khác nhau. Số thiếu cần được xác định lại sau từng bước, vì loại dòng trùng có thể làm thay đổi tổng. Tiêu chí trùng dùng 27 đặc trưng sau chuyển kiểu số, ngày gốc và nhãn chuẩn; giữ bản ghi đầu tiên và ghi nhật ký các dòng loại.

Bảng 2.2. Tình trạng đầu vào và yêu cầu xử lý tương ứng

Nội dung	Tình trạng ghi nhận	Yêu cầu phát sinh
Kiểu số	Một số cột có biểu diễn hỗn hợp.	Chuyển kiểu có theo dõi giá trị không chuyển được.
Ô thiếu	70 ô: diện tích 32; độ dày 30; logarit trục Y 4; định hướng 4.	Xác định vị trí thiếu và căn cứ khôi phục từng ô.
Trùng lặp	20 dòng trùng theo tiêu chí đặc trưng, ngày gốc và nhãn chuẩn.	Ghi rõ dòng giữ, dòng loại và tiêu chí so sánh.
Nhãn	28 biểu diễn cho bảy nhãn chuẩn.	Kiểm tra ánh xạ và thống nhất tên nhóm.
Chỉ số	Có giá trị đáng ngờ, cần kiểm tra quan hệ giữa các cột.	Phát hiện trước tham chiếu; lưu căn cứ khi sửa.
Ngày	Định dạng hỗn hợp; giá trị mô phỏng.	Chuẩn hóa hồ sơ, giữ giá trị gốc để truy vết.
Diện tích	Dải giá trị rộng, có giá trị rất lớn.	Kiểm tra tính hợp lệ; cân nhắc trục log.

Tương tự, 28 biểu diễn nhãn không đồng nghĩa 28 loại lỗi. Chuẩn hóa phải dựa trên ánh xạ đã kiểm tra. `Empty_Index` bằng 2031 hoặc `Log_Y_Index` bằng 18129 là dấu hiệu cần đối chiếu với quan hệ phái sinh và nguồn tham chiếu. Dấu hiệu phát hiện phải được ghi riêng với căn cứ chọn giá trị sửa. Diện tích lớn hoặc nằm ngoài râu boxplot chưa đủ căn cứ loại bản ghi.

2.3 Công cụ và môi trường thực hiện

2.3.1 Công cụ xử lý và trực quan hóa

Python và Jupyter Notebook tổ chức các bước cùng phần giải thích và đầu ra. Pandas đảm nhiệm đọc bảng, kiểm tra kiểu, chuẩn hóa, ghép nguồn và tổng hợp; NumPy hỗ trợ phép tính số, logarit. Tệp XLSX được đọc qua `openpyxl`. Công thức và điều kiện phải thể hiện rõ trong mã.

Matplotlib tạo biểu đồ tĩnh cho báo cáo [6]; Streamlit tổ chức dashboard, còn Plotly cung cấp biểu đồ tương tác [7]. `requests` đọc nguồn qua mạng; `json` xử lý phản hồi JSON. Phiên bản và lệnh chạy cần được lưu cùng sản phẩm; chỉ liệt kê thư viện thực sự sử dụng.

2.3.2 Căn cứ lựa chọn Python

Python phù hợp với yêu cầu dùng chung quy trình cho dữ liệu, biểu đồ và dashboard. Quy tắc chuẩn hóa hoặc công thức tỷ trọng được viết rõ có thể chạy lại với cùng đầu vào;

bảng thống kê được xuất để đưa vào báo cáo. Ưu điểm được xem xét là khả năng tổ chức và truy vết, chưa có phép đo để so sánh tốc độ hoặc hiệu quả với công cụ khác.

2.4 Yêu cầu phân tích và tiêu chí đọc kết quả

2.4.1 Đầu ra cho Q0–Q5

Các câu hỏi ở phần mở đầu được cụ thể hóa trong Bảng 2.3. Biểu đồ cần đi cùng bảng thống kê, cỡ mẫu và phạm vi tính. Kết quả hoàn chỉnh đặt ở Chương 4.

Bảng 2.3. Đầu ra và trọng tâm đọc kết quả cho Q0–Q5

Mã	Đầu ra cần có	Trọng tâm đọc kết quả
Q0	Bảng phát hiện, nhật ký và kiểm tra sau xử lý.	Phân biệt ô/dòng, căn cứ sửa và điều kiện toàn vẹn.
Q1	Thanh ngang, Pareto và bảng cơ cấu.	Thứ hạng, ba nhãn đầu, lũy kế 80% và chênh lệch cỡ mẫu.
Q2	Cột nhóm, cột 100% và tỷ trọng hai chiều.	Cơ cấu trong dòng thép và mức tập trung của từng nhãn.
Q3	Scatter độ sáng và bảng tứ phân vị.	Vùng trung tâm, mức chồng lấn và cỡ mẫu theo nhãn.
Q4	Boxplot độ dày và bảng nhãn theo dòng thép.	Trung vị, IQR, độ lệch chuẩn và số quan sát.
Q5	Boxplot diện tích trục log và bảng thống kê.	Trung vị, IQR, cực trị và điểm ngoài râu theo nhóm.

Ở Q0, bảng phát hiện được lập trước khi sử dụng giá trị tham chiếu. Nhật ký ghi vị trí, giá trị cũ/mới và căn cứ; kiểm tra sau xử lý gồm số dòng, kiểu, nhãn, khóa ghép và mức khớp nguồn. Q1 cần đọc thứ hạng, tỷ trọng ba nhãn đầu, số nhãn để đạt ít nhất 80% lũy kế và tỷ số cỡ mẫu lớn nhất/nhỏ nhất. Các chỉ số này mô tả cơ cấu mẫu, chưa xếp hạng thiệt hại.

Q2 dùng tỷ trọng dòng thép trong từng nhãn để xác định mức tập trung. Gọi $n_{g,s}$ là số bản ghi thuộc nhãn g và dòng thép s, điều kiện là

$$\max_{s} \frac{n_{g,s}}{\sum_{t} n_{g,t}} > 0{,}90. \tag{2.1}$$

Mốc trên 90% được sử dụng theo mục V.3 của tài liệu đọc [2], như một quy ước khám phá. Đây không phải chuẩn kỹ thuật ngành thép. Khi đọc cơ cấu nhãn trong A300/A400, mẫu số đổi sang tổng bản ghi của từng dòng thép, theo hai cách tính ở công thức 1.1.

Q3 xét khoảng P25–P75 của độ sáng tối thiểu. Nhãn g đáp ứng tiêu chí khi, với mọi nhãn $h \neq g$, có

$$\text{P75}_g < \text{P25}_h \quad \text{hoặc} \quad \text{P25}_g > \text{P75}_h. \tag{2.2}$$

Khoảng chạm đầu mút không đáp ứng điều kiện. Tiêu chí được bổ sung sau khảo sát kết quả, không phải giả thuyết xác định trước. Nó chỉ mô tả phần trung tâm; scatter và cực trị cần được đọc để nhận diện chồng lấn. Q4 ghi rõ cỡ mẫu; nhóm $N = 1$ chỉ mô tả một bản ghi, chưa đánh giá biến thiên hoặc suy rộng. Q5 sử dụng đại lượng thống kê thay cho nhận xét "khác biệt rõ" chưa định nghĩa; kiểm tra diện tích dương trước dùng trục log, tính râu trên thang gốc.

2.4.2 Yêu cầu dashboard và kiểm thử

Dashboard cần lọc theo dòng thép, nhãn và khoảng độ dày; KPI, biểu đồ, bảng trong phần phân tích lỗi sử dụng cùng tập con. Tab chất lượng thể hiện tình trạng toàn nguồn và phải ghi rõ phạm vi. Tập rỗng cần có thông báo; CSV xuất đúng phạm vi đã mô tả. Chức năng đọc lại nguồn phải kiểm tra dữ liệu mới, giữ bản hợp lệ gần nhất khi nguồn lỗi. Kiểm thử bao gồm lọc kết hợp, tập rỗng, xuất dữ liệu, cập nhật và lỗi nguồn. Phạm vi năm thương mại độc lập với bộ lọc lỗi.

2.5 Định hướng thực hiện và tiểu kết chương

Khảo sát xác định những vấn đề cần giải quyết trước khi diễn giải biểu đồ: chuẩn hóa kiểu và nhãn, xác định trùng, kiểm tra quan hệ nội tại, xác nhận khóa rồi khôi phục có truy vết. Chương 3 triển khai bằng Python; Chương 4 đối chiếu kết quả với yêu cầu tại mục 2.4. Tình trạng đầu vào, cách thực hiện và bằng chứng được trình bày theo mạch này.

Tài liệu tham khảo

[1] M. Buscema, S. Terzi và W. Tastle, *Steel Plates Faults* [Bộ dữ liệu], UCI Machine Learning Repository, 2010. Giấy phép CC BY 4.0.

DOI: 10.24432/C5J88N. Truy cập ngày 11/10/2026.

[2] Đinh Nhật Anh, Nguyễn Thị Phương và Nguyễn Lê Ngọc Khôi, *Phân tích nguy cơ xảy ra lỗi trong dây chuyền sản xuất thép*, tài liệu đọc, không ghi năm, mục V.3. Tệp: [Reading]-Data-Analytics-in-Manufacturing.pdf.

[3] pandas development team, *pandas.merge*, tài liệu pandas.

https://pandas.pydata.org/docs/reference/api/pandas.merge.html. Truy cập ngày 11/10/2026.

[4] NIST/SEMATECH, *e-Handbook of Statistical Methods*, mục 1.3.3.7: Box Plot và mục 1.3.5.6: Measures of Scale.

https://www.itl.nist.gov/div898/handbook/eda/section3/boxplot.htm.

https://www.itl.nist.gov/div898/handbook/eda/section3/eda356.htm. Truy cập ngày 11/10/2026.

[5] National Institute of Standards and Technology (NIST), *Dataplot Reference Manual*, mục Correlation.

https://www.itl.nist.gov/div898/software/dataplot/refman2/auxillar/correlat.htm. Truy cập ngày 11/10/2026.

[6] Matplotlib development team, *Quick start guide*, tài liệu Matplotlib.

https://matplotlib.org/stable/users/explain/quick_start.html. Truy cập ngày 11/10/2026.

[7] Streamlit, *Widget behavior*, tài liệu Streamlit.

https://docs.streamlit.io/develop/concepts/architecture/widget-behavior. Truy cập ngày 11/10/2026.

[8] A. Kharal, *Explainable Artificial Intelligence Based Fault Diagnosis and Insight Harvesting for Steel Plates Manufacturing*, arXiv:2008.04448, bản v1, 2020.

https://arxiv.org/abs/2008.04448. Truy cập ngày 11/10/2026.